

# Capítulo 1

## Modelagem Matemática

### 1.1 Introdução

Modelagem matemática é a área do conhecimento que estuda maneiras de desenvolver e implementar modelos matemáticos de sistemas reais.

- Modelagem caixa branca. *Modelagem pela física ou natureza do processo* ou ainda *modelagem fenomenológica* ou *modelagem conceitual*.
- Identificação de sistemas. *Modelagem empírica*.

O objetivo deste capítulo é introduzir alguns conceitos básicos e princípios fundamentais que serão úteis no estudo de técnicas de identificação.

## 1.2 Alguns Conceitos Básicos

- O que é um modelo matemático?
- Para que serve um modelo?
- Que tipo de modelo deve ser utilizado?

### 1.2.1 Considerações freqüentemente feitas em modelagem

- *Linearidade*. Princípio da superposição.
- *Invariância no tempo*. A consideração de invariância temporal implica que *a dinâmica que está regulando a evolução temporal é a mesma*.
- *Concentração de parâmetros*. As variáveis de interesse variam apenas com o tempo e não no espaço.

#### Exemplo 1.2.1. *Linearidade — um sistema estático*

A equação da reta  $y = 5x$ . Este “sistema” é estático e é linear pois satisfaz o princípio da superposição. Se  $x_1 = 2$ , então  $y_1 = 10$ ; se  $x_2 = -3$ , então  $y_2 = -15$ . O princípio da superposição estabelece que se  $x_3 = 4x_1 + 5x_2 = -7$ , então tem-se a seguinte relação:  $y_3 = 4y_1 + 5y_2 = -35$ . Por outro lado,  $y_3 = 5x_3 = -35$ .

Um outro exemplo é  $y = 2 + 5x$ , que também é a equação de uma reta. Tal sistema não é mais linear.  $\square$

**Exemplo 1.2.2.** *Linearidade — um sistema dinâmico*

$$5u(t)\frac{dy}{dt} + y(t) - 10u(t) = 0,$$

A equação acima é não-linear. A equação linear equivalente é

$$\tau \frac{dy}{dt} + y(t) - Ku(t) = 0.$$

□

**Exemplo 1.2.3.** *Invariância*

Seja  $y(t) = \text{sen}(u(t))$ . Para a entrada  $u_1(t)$  a saída será  $y_1 = \text{sen}(u_1(t))$ . Deslocando  $u_1(t)$  no tempo, tem-se  $u_2(t) = u_1(t - t_0)$  e

$$\begin{aligned} y_2(t) &= \text{sen}(u_2(t)) = \text{sen}(u_1(t - t_0)), \\ y_1(t - t_0) &= \text{sen}(u_1(t - t_0)), \end{aligned}$$

Como  $y_2(t) = y_1(t - t_0)$  o sistema é invariante.

Seja  $y(t) = tu(t)$  e as mesmas entradas acima. Nesse caso,

$$\begin{aligned} y_1(t) &= tu_1(t) \\ y_2(t) &= tu_2(t) = tu_1(t - t_0). \end{aligned}$$

Como  $y_1(t - t_0) = (t - t_0)u_1(t - t_0) \neq y_2(t)$ , o sistema  $y(t) = tu(t)$  não é invariante no tempo. □

### Exemplo 1.2.4. *Sistema a parâmetros distribuídos*

Seja uma viga presa ao teto e com a extremidade inferior livre. A posição de qualquer parte da viga é determinada pela sua distância  $x$  ao teto. Na extremidade livre é aplicado um conjugado. O ângulo de torção  $\theta$  vai depender, não apenas do tempo, mas também da posição conforme

$$\frac{\partial^2 \theta}{\partial x^2} = K \frac{\partial^2 \theta}{\partial t^2}.$$

□

### 1.2.2 Tipos de modelos

- *Modelos estáticos e dinâmicos.*
- *Modelos discretos e contínuos.*
- *Modelos autônomos e não autônomos.*
- *Modelos monovariáveis e multivariáveis.*
- *Modelos determinísticos e estocásticos.*
- *Modelos paramétricos e não paramétricos.*

**Exemplo 1.2.5.** *Modelo discreto de um sistema biológico*

Considere a população de besouros. Um modelo simples é

$$\begin{aligned} L(k+1) &= \nu B(k) \\ C(k+1) &= L(k)[1 - \mu_l] \\ B(k+1) &= C(k)[1 - \mu_c] + B(k)[1 - \mu_b], \end{aligned}$$

sendo  $L$  a população de larvas,  $C$  número de casulos,  $B$  o número de besouros,  $\nu$  a taxa de natalidade,  $\mu_l$ ,  $\mu_c$  e  $\mu_b$  as taxas de mortalidade de larvas, casulos e de besouros.  $\square$

**Exemplo 1.2.6.** *Modelo não autônomo de sistema biológico*

$A(k)$  é a quantidade de agrotóxico aspergido por metro quadrado. Tal agrotóxico somente afeta as larvas matando uma parte delas, então

$$\begin{aligned} L(k+1) &= \nu B(k) \\ C(k+1) &= L(k)[1 - \mu_l - \mu_a A(k)] \\ B(k+1) &= C(k)[1 - \mu_c] + B(k)[1 - \mu_b], \end{aligned}$$

sendo que  $\mu_a$  é a taxa de mortalidade devida exclusivamente à ação do agrotóxico.  $\square$

**Exemplo 1.2.7.** *Modelos monovariáveis e multivariáveis*

A primeira equação diferencial mostrada é um modelo monovariável de uma entrada,  $u(t)$  e uma saída  $y(t)$ , portanto é um modelo SISO. Os modelos dos besouros podem ser interpretados como modelos multivariáveis.  $\square$

**Exemplo 1.2.8.** *Um modelo estocástico simples*

Se o modelo da população de besouros não explica exatamente as observações haverá um erro. Essa diferença reflete incertezas tanto nas medições quanto na própria forma da equação e é normalmente expressa usando-se uma variável aleatória. Portanto,

$$B(k+1) = C(k)[1 - \mu_c] + B(k)[1 - \mu_b] + e(k+1).$$

$\square$

**Exemplo 1.2.9.** *Modelos paramétricos e não paramétricos*

O seguinte modelo é paramétrico

$$H(s) = \frac{1}{s^2 + 0,4s + 1}.$$

A resposta ao impulso  $h(t) = \mathcal{L}^{-1}\{H(s)\}$  do modelo é




FIGURA 1.1: Resposta ao impulso.




FIGURA 1.2: Resposta em frequência de  $H(j\omega) = \mathcal{F}\{h(t)\}$ .

□

### 1.2.3 Representações de modelos lineares

- *Função de transferência.* A transformada da resposta ao impulso  $h(t)$  do sistema. Para um sinal  $x(t)$

$$X(s) = \mathcal{L}\{x(t)\} = \int_0^{\infty} x(t)e^{-st}dt.$$

$$x(t) = \mathcal{L}^{-1}\{X(s)\} = \frac{1}{2\pi j} \int_{\sigma-j\infty}^{\sigma+\infty} X(s)e^{st}ds,$$

sendo  $s = \sigma + j\omega$ .

No caso discreto usa-se a transformada  $Z$ , definida como

$$X(z) = \mathcal{Z}\{x(k)\} = \sum_{k=-\infty}^{k=0} x(k)z^{-k}.$$

$$x(k) = \mathcal{Z}^{-1}\{X(z)\} = \frac{1}{2\pi j} \oint X(z)z^{k-1}dz.$$

A *transformada de Fourier* de  $h(t)$  é  $H(j\omega)$ , a *resposta em frequência* do sistema. A transformada de Fourier de um sinal  $x(t)$  é

$$X(j\omega) = \mathcal{F}\{x(t)\} = \int_{-\infty}^{\infty} x(t)e^{-j\omega t}dt,$$

$$x(t) = \mathcal{F}^{-1}\{X(j\omega)\} = \frac{1}{2\pi} \int_{-\infty}^{\infty} X(j\omega)e^{j\omega t}d\omega.$$



- *Representação no espaço de estados.*

$$\dot{\mathbf{x}} = f(\mathbf{x}),$$

$$\dot{\mathbf{x}} = f(\mathbf{x}, \mathbf{u}(t)).$$

Assumindo linearidade e acrescentando o processo de medição

$$\dot{\mathbf{x}} = A\mathbf{x} + B\mathbf{u}$$

$$\mathbf{y} = C\mathbf{x} + D\mathbf{u}.$$

E para o caso discreto

$$\mathbf{x}(k+1) = \Phi\mathbf{x}(k) + \Gamma\mathbf{u}(k)$$

$$\mathbf{y}(k) = C_d\mathbf{x}(k) + D_d\mathbf{u}(k).$$

- *Modelos AR e ARX*

$$y(k) = a_1y(k-1) + a_2y(k-2) + \dots + a_{n_y}y(k-n_y).$$

$$y(k) = a_1y(k-1) + \dots + a_{n_y}y(k-n_y) \\ + b_1u(k-1) + \dots + b_{n_u}u(k-n_u).$$

- *Modelo auto-regressivo com média móvel e entrada exógena* (ARMAX)

$$y(k) = a_1 y(k-1) + \dots + a_{n_y} y(k-n_y) + b_1 u(k-1) + \dots + b_{n_u} u(k-n_u) + c_1 \xi(k-1) + \dots + c_{n_\xi} \xi(k-n_\xi) + \xi(k).$$

**Exemplo 1.2.10.** *Função de transferência*

Um modelo discreto é

$$H(z) = \frac{0,1075z^2 + 0,2151z + 0,1075}{z^2 - 1,6129z + 0,8280},$$

cuja resposta ao impulso é




FIGURA 1.3: Resposta ao impulso de um modelo discreto

□

**Exemplo 1.2.11.** *Modelos em espaço de estados*

Os modelos da população de besouros podem ser representados no espaço de estados como

$$\begin{bmatrix} L(k+1) \\ C(k+1) \\ B(k+1) \end{bmatrix} = \begin{bmatrix} 0 & 0 & \nu \\ 1 - \mu_l & 0 & 0 \\ 0 & 1 - \mu_c & 1 - \mu_b \end{bmatrix} \begin{bmatrix} L(k) \\ C(k) \\ B(k) \end{bmatrix},$$

e

$$\begin{aligned} \begin{bmatrix} L(k+1) \\ C(k+1) \\ B(k+1) \end{bmatrix} &= \begin{bmatrix} 0 & 0 & \nu \\ 1 - \mu_l & 0 & 0 \\ 0 & 1 - \mu_c & 1 - \mu_b \end{bmatrix} \begin{bmatrix} L(k) \\ C(k) \\ B(k) \end{bmatrix} + \\ &+ \begin{bmatrix} 0 \\ -L(k)\mu_a \\ 0 \end{bmatrix} A(k). \end{aligned}$$

□

**Exemplo 1.2.12.** *Modelo ARX de conversor buck*

Um modelo ARX de um conversor CC–CC buck é

$$\begin{aligned} y(k) &= 1,7649y(k-1) - 0,8027y(k-2) + 0,8661u(k-3) \\ &\quad - 0,73578u(k-1) + 0,07513u(k-2) + \xi(k), \end{aligned}$$

□

### 1.3 Estimação de Parâmetros

#### Exemplo 1.3.1. *Estimação de parâmetros de uma reta*

$f(\cdot)$  pode ser bem aproximada por uma reta. Assim,  $\hat{f}(\cdot)$  é a função estimada, ou seja,  $y = \theta_1 + \theta_2 x$ .




FIGURA 1.4: Os dados medidos (x), e a reta ajustada usando regressão linear (—). Esta reta é parametrizada por  $[\theta_1 \ \theta_2]^T$ , sendo  $\theta_1 = -1,55 \times 10^{-3}$  o valor de  $y$  quando  $x = 0$  e  $\theta_2 = 6,98 \times 10^{-4}$  é a inclinação da reta.

□

1. A estimação de parâmetros é uma etapa que sucede a escolha da função  $\hat{f}(\cdot)$ .
2. A escolha de uma aproximação de  $f(\cdot)$  foi fácil nesse exemplo.
3. A função  $\hat{f}(\cdot)$  é *linear nos parâmetros*  $\theta_1$  e  $\theta_2$ . Ela pode ser decomposta da seguinte forma  $y = [1 \ x][\theta_1 \ \theta_2]^T$ .
4. Os parâmetros acima foram estimados de uma só vez: *estimação em batelada*.

**Exemplo 1.3.2.** *Cálculo dos parâmetros de uma reta*

O uso de dois pontos resultará no sistema de duas equações

$$\begin{aligned} y_1 &= \theta_1 + x_1\theta_2 \\ y_2 &= \theta_1 + x_2\theta_2. \end{aligned}$$

Tomando os pontos  $(x_1, y_1) = (144, 0; 0, 098)$  e  $(x_2, y_2) = (158, 4; 0, 109)$  do conjunto de medidas, tem-se

$$\begin{bmatrix} 0,098 \\ 0,109 \end{bmatrix} = \begin{bmatrix} 1 & 144,0 \\ 1 & 158,4 \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}.$$

Portanto,

$$\begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} 11,00 & -10,00 \\ -0,069 & 0,069 \end{bmatrix} \begin{bmatrix} 0,098 \\ 0,109 \end{bmatrix} = \begin{bmatrix} -1,200 \times 10^{-2} \\ 7,639 \times 10^{-4} \end{bmatrix}.$$




FIGURA 1.5: Determinação exata dos parâmetros de uma reta

Dados medidos são marcados com cruces, e a reta  $y = -1,200 \times 10^{-2} + 7,639 \times 10^{-4}x$ , com traço.

□

## 1.4 Modelagem Baseada na Física do Processo




FIGURA 1.6: Esquema de planta piloto de bombeamento

Em aplicações de controle de vazão de saída,  $q_o$ , ou de nível do tanque,  $h$ , um modelo do processo relacionaria o sinal de atuação (entrada)  $u(t)$  a uma dessas variáveis.

Considerações simplificadoras:

1. o sistema será considerado a parâmetros concentrados;
2. a perda de carga dentro dos dutos será desprezada;
3. a área do tanque é constante; constante;

4. a dinâmica do inversor e do conjunto moto-bomba pode ser desprezada;
5. a água é incompressível e seu peso específico não varia;
6. a pressão atmosférica em cada ponto da planta piloto é a mesma.

#### 1.4.1 A equação diferencial

O ponto de partida na modelagem deste sistema é

$$\frac{d m}{d t} = \omega_i - \omega_o,$$

Como  $m = V \rho$  e a área do tanque é constante, tem-se

$$m = A h \rho,$$

$\rho$  é a massa específica e  $h$  é a altura.

$$\begin{aligned} \rho A \frac{d h}{d t} &= q_i \rho - q_o \rho \\ \frac{d h}{d t} &= \frac{q_i - q_o}{A}, \end{aligned}$$

$q_i$  e  $q_o$ : vazões volumétricas.



### 1.4.2 Relações algébricas

Usando a lei de Bernoulli, tem-se

$$q = k\sqrt{\Delta P}.$$

Para a tubulação de saída de água, tem-se

$$q_o = k_o\sqrt{P - P_{\text{atm}}}.$$

Para o duto de recalque, tem-se

$$q_i = k_i\sqrt{P_b - P}.$$

Usando-se o peso específico da água  $\gamma$ , tem-se

$$P = \gamma h + P_{\text{atm}},$$

$$\frac{dh}{dt} = \frac{k_i\sqrt{P_b - \gamma h - P_{\text{atm}}} - k_o\sqrt{\gamma h}}{A}.$$

A partir da geometria do tanque, os valores aproximados destes parâmetros são:  $A = 2,5 \text{ m}^2$ ,  $P_{\text{atm}} = 10.300 \text{ kgf/m}^2$  e  $\gamma = 1000 \text{ kgf/m}^3$ . Os parâmetros  $k_i$  e  $k_o$  precisam ser determinados.




FIGURA 1.7: Relação entre sinal de comando do inversor e pressão na saída da bomba. Os dados medidos são marcados com (x), e a reta ajustada usando regressão linear, com (—).

$$P_b = 3554,9 + 682,8 u(t).$$

A saída de água do tanque está localizada a 0,114 m do fundo. É necessário determinar  $K$  que, adicionado ao modelo, resultará em  $dh/dt = 0$  para  $h = 0$ . Portanto,

$$\begin{aligned} \frac{dh}{dt} &= \frac{k_i \sqrt{P_b^* - P_{\text{atm}}}}{A} + K = 0 \\ K &= -\frac{k_i \sqrt{P_b^* - P_{\text{atm}}}}{A}, \end{aligned}$$

sendo que  $P_b^* = 14.213,4 \text{ kgf/m}^2$ .

### 1.4.3 Determinação de parâmetros

Para o duto de entrada obteve-se




FIGURA 1.8: Dados medidos (x), a reta ajustada usando regressão linear(–). O eixo das abcissas é  $(P_b - \gamma h - P_{atm})^{1/2}$ . A inclinação da reta ajustada é uma estimativa de  $k_i$ .

$$q_i = -1,87 \times 10^{-2} + 5,60 \times 10^{-4} \sqrt{P_b - \gamma h - P_{atm}},$$

portanto  $k_i = d q_i / d \sqrt{P_b - \gamma h - P_{atm}} = 5,60 \times 10^{-4} \text{ m}^4/\text{s}(\text{kgf})^{1/2}$ .

Para o duto de deságüe, obteve-se




FIGURA 1.9: Os dados medidos são marcados com (x), e a reta ajustada usando regressão linear, com (—). O eixo das abcissas é  $(\gamma h)^{1/2}$ . A derivada da função ajustada é uma estimativa de  $k_o$ .

$$q_o = 1,59 \times 10^{-2} + 3,06 \times 10^{-5} \sqrt{\gamma h} + 6,26 \times 10^{-6} \gamma h, \quad (1.1)$$

$$\text{logo, } k_o = dq_o/d\sqrt{\gamma h} = 3,06 \times 10^{-5} + 1,25 \times 10^{-5} \sqrt{\gamma h} \text{ m}^4/\text{s(kgf)}^{1/2}.$$

Finalmente, tem-se

$$\frac{dh}{dt} = \frac{5,60 \times 10^{-4} \sqrt{3554,9 + 682,8 u(t) - 1000h - 10300}}{A} - \frac{(3,06 \times 10^{-5} + 1,25 \times 10^{-5} \sqrt{1000h}) \sqrt{1000h}}{A} - 0,014$$

que pode ser simulado usando-se os seguintes arquivos: eq\_bomb, sim\_bomb, ens\_25 e ens\_26 @.

#### 1.4.4 Sintonia




FIGURA 1.10: Resposta da vazão a uma variação em degrau do sinal de entrada  $u(t)$ . Dados medidos (ens\_25 @) são indicados por (- -), e (—) representam os dados obtidos usando-se o modelo. Os picos são devidos ao ruído induzido no processo de medição.

1. *Ajuste da constante de tempo.*  $\dot{h}_{\text{sintonizado}} = 0,4 \dot{h}$ .
2. *Ajuste do ganho.* Aumentar a amplitude do degrau de entrada de 16,34 mA a 17,05 mA, visto pelo modelo, para 16,34 mA a  $1,012 \times 17,05$  mA.




FIGURA 1.11: Resposta da vazão a uma variação em degrau do sinal de entrada  $u(t)$ . Dados medidos (ens\_25 @) são indicados por (- -) e (-) representam os dados obtidos usando-se o modelo sintonizado (com ajustes).

### 1.4.5 Validação

Os ajustes descritos foram eficazes, mas quão gerais são esses ajustes?




FIGURA 1.12: Resposta da vazão a uma variação em degrau do sinal de entrada  $u(t)$  diferente daquela usada para sintonizar o modelo. Dados medidos (ens\_26 @) são indicados por (- -), e (-) representam os dados obtidos usando-se o modelo sintonizado anteriormente.

## 1.5 Identificação de Sistemas

Identificação de sistemas é um procedimento alternativo que se propõe a obter um modelo matemático que explique a relação de causa e efeito presente nos dados.

Tenta-se responder à pergunta:

**Que modelo há que, ao ser excitado pela entrada  $u(k)$ ,  
resulta na saída  $y(k)$ ?**

As principais etapas de um problema de identificação são:

1. *Testes dinâmicos e coleta de dados;*
2. *Escolha da representação matemática a ser usada;*
3. *Determinação da estrutura do modelo;*
4. *Estimação de parâmetros;*
5. *Validação do modelo.*



### Exemplo 1.5.1. *Dados de identificação*

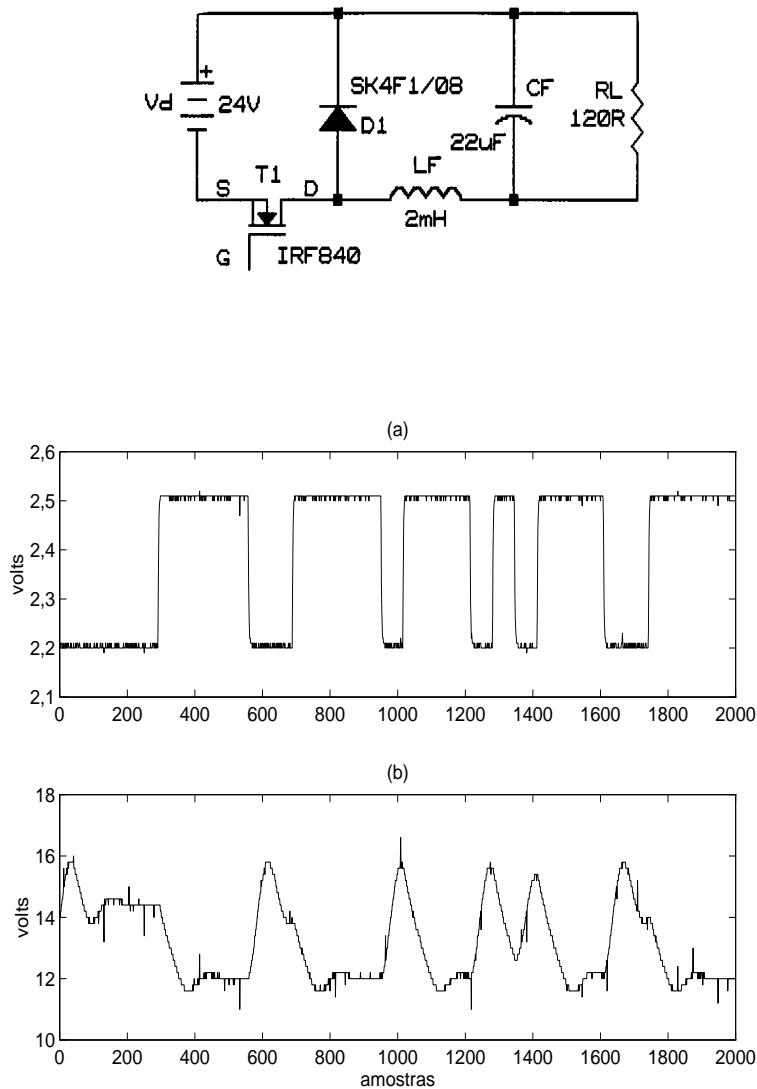


FIGURA 1.13: Dados de entrada e saída de um conversor buck.

(a) sinal de entrada, tensão que define a razão cíclica do conversor, e (b) sinal de saída, tensão elétrica na saída do conversor (acq7000 @).

□

## 1.6 Simulação de Modelos

A fim de avaliar o desempenho de um modelo, é necessário simulá-lo, ou seja, é necessário resolver as equações que compõem o modelo. A forma de simular um modelo vai depender da representação utilizada.

### 1.6.1 Modelos contínuos

A simulação de modelos contínuos normalmente envolve a solução de equações diferenciais do tipo  $\dot{x} = f(x, t)$ .

A aproximação explícita de Euler é

$$\dot{x}(t_k) \approx \frac{x(k+1) - x(k)}{T}.$$

A aproximação implícita de Euler é

$$\dot{x}(t_k) \approx \frac{x(k) - x(k-1)}{T},$$

sendo que  $T$  é o intervalo de integração. Tais aproximações resultam nas seguintes fórmulas de integração numérica:

$$x(k) = x(k-1) + T f(x(k-1), t_{k-1}),$$

$$x(k) = x(k-1) + T f(x(k), t_k).$$

**Exemplo 1.6.1.** *Simulação usando a fórmula de Euler*

Seja a equação diferencial  $\dot{x} = -6x + 5e^{-t}$ . Para  $T = 0,3$ , a aproximação explícita de Euler resulta em

$$x(k) = x(k-1) + 0,3 \left( -6x(k-1) + 5e^{-t_{k-1}} \right).$$

Para resolver a equação diferencial  $\dot{x} = -6x + 5e^{-t}$  usando a equação acima, basta escolher uma condição inicial  $x(0)$  e resolver tal equação para  $k = 1, 2, \dots$   $\square$

Um dos algoritmos de integração numérica mais utilizados na simulação de modelos contínuos é o algoritmo de *Runge-Kutta de quarta ordem*:

$$\begin{aligned} A &= f(x(k-1), t_{k-1}) \\ B &= f\left(x(k-1) + \frac{T}{2}A, t_{k-1} + \frac{T}{2}\right) \\ C &= f\left(x(k-1) + \frac{T}{2}B, t_{k-1} + \frac{T}{2}\right) \\ D &= f(x(k-1) + TC, t_{k-1} + T) \\ x(k) &= x(k-1) + \frac{T}{6}(A + 2B + 2C + D). \end{aligned}$$

### 1.6.2 Modelos discretos

Não requer nenhum algoritmo especial.

**Exemplo 1.6.2.** *Simulação de modelo ARX*

Seja o modelo de um conversor CC-CC

$$\begin{aligned} y(k) = & 1,7649y(k-1) - 0,8027y(k-2) + 0,8661u(k-3) \\ & - 0,73578u(k-1) + 0,07513u(k-2) + \xi(k), \end{aligned}$$

Escolhendo-se a condição inicial  $y(1) = y(2) = 14\text{ V}$  e a entrada  $u(0) = u(1) = 2,3\text{ V}$ ,  $u(2) = u(3) = 2,4\text{ V}$  etc, tem-se

$$\begin{aligned} y(3) = & 1,7649(14) - 0,8027(14) + 0,8661(2,3) \\ & - 0,73578(2,4) + 0,07513(2,3) = 13,8698 \\ y(4) = & 1,7649(13,8698) - 0,8027(14) + 0,8661(2,3) \\ & - 0,73578(2,4) + 0,07513(2,4) = 13,6474 \\ y(5) = & 1,7649(13,6474) - 0,8027(13,8698) + 0,8661(2,4) \\ & - 0,73578(2,3) + 0,07513(2,4) = 13,5197 \\ y(6) = & 1,7649(13,5197) - 0,8027(13,6474) + 0,8661(2,4) \\ & - 0,73578(2,4) + 0,07513(2,3) = 13,3917 \\ & \vdots \quad \quad \quad \vdots \end{aligned}$$

$y(1), y(2), \dots$  é a resposta do modelo à entrada  $u(0), u(1), \dots$

□